

# Approche dynamique de la ségrégation: une analyse à partir de données de téléphonie mobile

Lino Galiana (D2E)

En collaboration avec Benjamin Sakarovitch (SSP-lab), François Sémécurbe (SSP-lab) et Zbigniew Smoreda (Orange Labs)

Séminaire du Département des Etudes Economiques

19 février 2019

# Introduction

# Une photographie de la distribution du revenu (Marseille)

- ▶ Données fiscales: concentration spatiale des premiers et derniers déciles à Marseille
  - ▶ Quelle dynamique infra-journalière ?

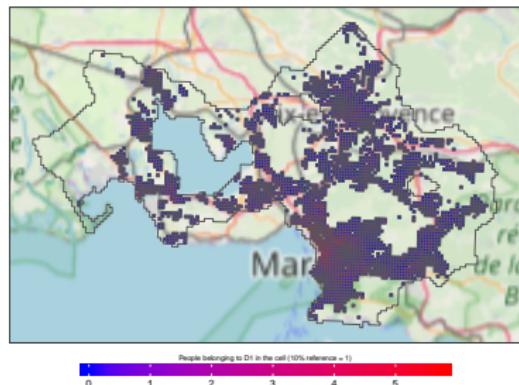


Figure 1: Répartition spatiale des ménages du premier décile

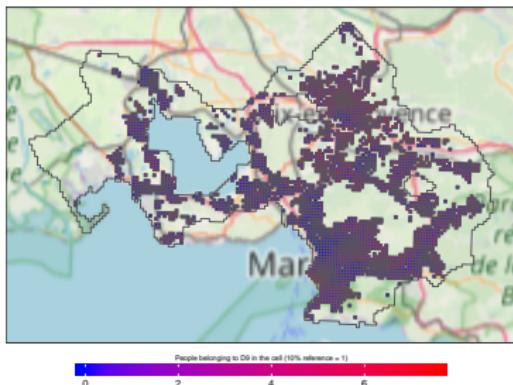


Figure 2: Répartition spatiale des ménages du dernier décile

# Pourquoi adopter une vision dynamique de la ségrégation ?

- ▶ Ségrégation n'est pas un processus figé:
  - ▶ Dimension temporelle: composition d'un quartier évolue dans le temps
  - ▶ Résidence ne représente pas nécessairement l'endroit où l'individu passe du temps
- ▶ Questions de recherche:
  - ▶ Comment les mobilités affectent-elles la ségrégation urbaine ?
  - ▶ La ségrégation résidentielle masque-t-elle une dynamique infra-journalière?
- ▶ Dynamique infra-journalière marquée:
  - ▶ Davis et al. (2017): ségrégation lieux de sortie (restaurants)  
50% inférieure ségrégation résidentielle
  - ▶ Le Roux et al. (2017): ségrégation jour inférieure de 15 à 30% à la ségrégation nocturne

# Pourquoi utiliser des données de téléphonie pour étudier la ségrégation?

- ▶ Ségrégation principalement étudiée à partir d'indices
  - ▶ Indice de dissimilarité (Duncan & Duncan, 1955)

$$ID = \frac{1}{2} \sum_{j=1}^J \left| \frac{w_j}{W_T} - \frac{n_j - w_j}{N_T - W_T} \right|$$

- ▶ Données administratives ⇒ ségrégation résidentielle:
  - ▶ Vision statique de la ségrégation
  - ▶ Séparation groupes sociaux dans l'espace résidentiel
  - ▶ Pas d'information sur lieux fréquentés
- ▶ Mobilités affectent de manière continue la distribution spatiale du revenu
  - ▶ Besoin de données géolocalisées à haute-fréquence...
  - ▶ ... qui doivent être combinées aux données classiques pour caractériser individus

## Approche adoptée

- ▶ On se propose d'étudier la **dynamique infra-journalière**:
  - ▶ **48 points**: 24 pour les jours de semaine, 24 pour le weekend
- ▶ Implique de construire des **indices de ségrégation dépendant du temps**
  - ▶ Construire une série d'indices de dissimilarité pour chaque ville
- ▶ Champs: **unités urbaines (UU)** de **Lyon** et **Marseille**
  - ▶ **Filosofi**: ménages dont domicile dans les limites UU
  - ▶ **Téléphonie**: ménages dont domicile simulé dans limites UU (simulation niveau national puis restriction)

## Enjeux

- ▶ Champ de recherche nouveau
- ▶ Pouvoir d'inférence dépend de la qualité de la combinaison des sources
- ▶ Nécessite un **fort investissement méthodologique**
  - ▶ Données ne sont pas produites pour une exploitation statistique
  - ▶ Assurer qualité de la combinaison avec données administratives
- ▶ Contribution:
  - ▶ Combiner données de téléphonie et données traditionnelles
  - ▶ Proposer une méthodologie pour assurer robustesse de la combinaison
  - ▶ Décrire évolution ségrégation à une échelle spatiale et temporelle fine

# Introduction

## Données

Données de téléphonie mobile

Données fiscales

## Méthodologie

## Résultats

Recalage

## Conclusion

## Données

## Données de téléphonie mobile

# Comptes rendus d'appels (CDR)

- ▶ Données Orange Septembre 2007, 18.5 millions de carte SIM
  - ▶ Appels et SMS: 3 milliards d'événements (France métropolitaine)
  - ▶ Géolocalisation au niveau antenne relais (présence exacte inconnue)
- ▶ Utilise pas la dimension des interactions
  - ▶ Futur travail sur ségrégation sociale

	mean	s.d.	min	P10	P25	median	P75	P90	max
Average number of daily events by user over the month	6.67	8.71	1	1.60	2.39	4.09	7.90	14.24	6260
Number distincts days phone users appear	19.98	9.16	1	5	13	23	28	30	30
Number of observations:					3,024,884,663				
Number of unique phone users:					18,541,440				

Table 1: Septembre 2007 Call Details Record: summary statistics

# CDR: dimension temporelle

- ▶ Pas une trace continue
  - ▶ Individu moyen: détecté 7 fois par jour
  - ▶ Hétérogénéité forte des comportements
- ▶ Utilisation inégale du téléphone selon l'heure

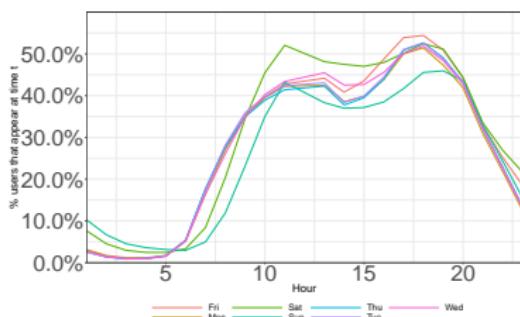


Figure 3: Utilisateurs détectés

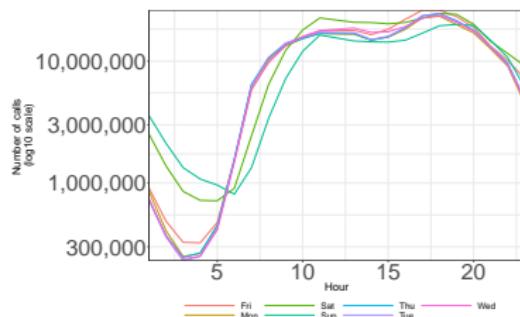


Figure 4: Appels (log)

## CDR: dimension spatiale

- ▶  $\approx 18\,000$  antennes à l'échelle nationale (4000 à Paris)
- ▶ Répartition non homogène des antennes (niveau des observations)
- ▶ Privilégier analyse urbaine

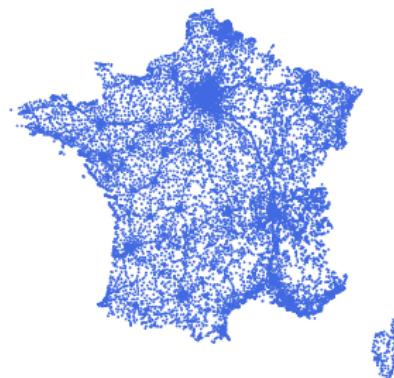


Figure 5: Répartition nationale des antennes

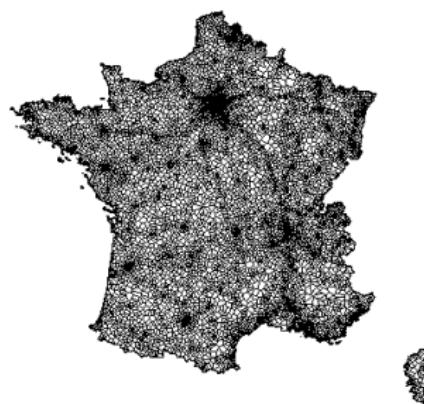
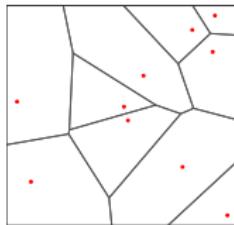
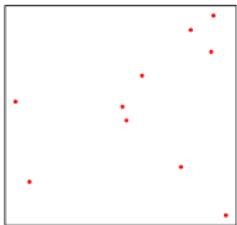


Figure 6: Aires de couverture estimées

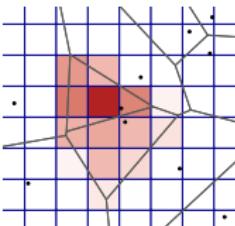
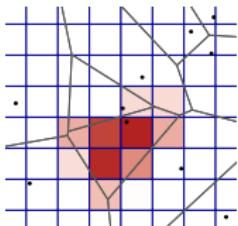
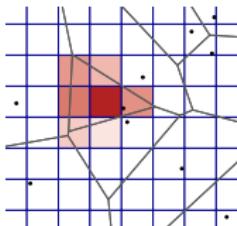
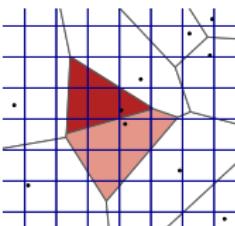
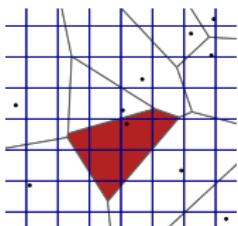
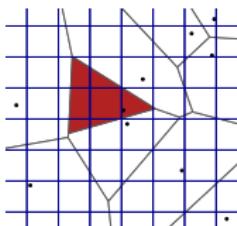
# Granularité spatiale



- ▶ Littérature ne distingue pas:
  - ▶ Aire de couverture: passage d'observations au niveau antenne à une aire de présence
  - ▶ Unité statistique: niveau des agrégats économiques considérés
- ▶ Modèle couverture: **tesselation de Voronoi**
  - ▶ Chaque point espace relié à l'antenne la plus proche
  - ▶ En l'absence d'informations sur couverture effective, simplification difficile à éviter
- ▶ Cependant, **ne doit pas être l'unité statistique d'analyse**
  - ▶ Dépend de la densité locale d'antennes
  - ▶ Partition espace trop hétérogène

# Probabilisation de la présence

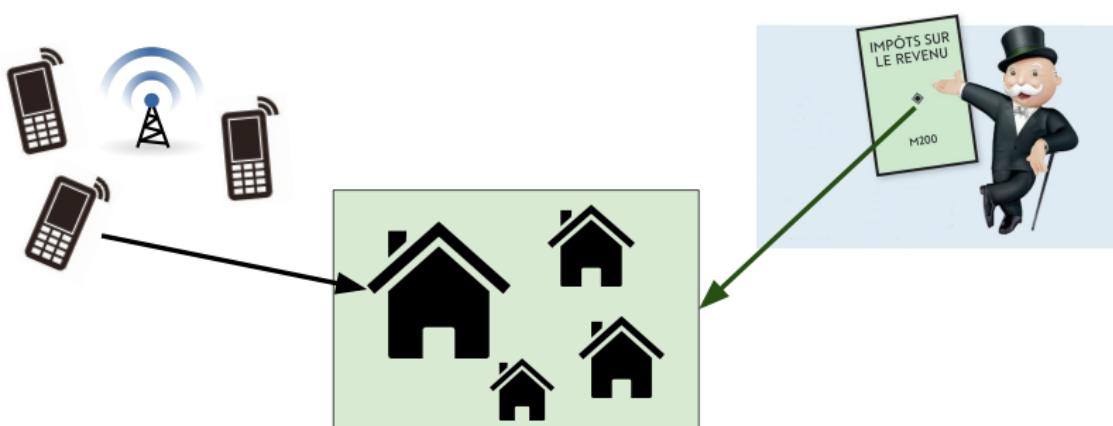
- ▶ S'abstraire du voronoi en probabilisant la présence au niveau de carreaux de taille fixe
  - ▶ Sachant que l'appel a été transmis par l'antenne  $v_j$ , quelle est la probabilité que l'individu soit présent dans un lieu donné  $c_i$ ?
  - ▶ Passage par règle de Bayes [Détails](#)
- ▶ Carreaux de 500m
  - ▶ Téléphonie: probabilisation présence & domicile au carreau
  - ▶ Filosofi: agrégats locaux sur cette grille



## Données fiscales

# Principe

- ▶ Caractériser utilisateurs de téléphone à partir lieu de vie
- ▶ Probabilité d'appartenir au premier/dernier décile en fonction de la distribution du revenu observée dans données fiscales



# Données Filosofi

- ▶ Données fiscales géolocalisées ( $x, y$ )
  - ▶ Revenu par unité de consommation
- ▶ Ségrégation économique sur critère de revenu
  - ▶ On s'intéresse aux extrêmes de la distribution du revenu (premier et dernier déciles)
  - ▶ Définition relative du revenu: est-on plus riche/pauvre que les personnes vivant dans la même UU ?
- ▶ **Approche bimodale:** décompose population en classes exclusives
  - ▶ Premier décile vs reste
  - ▶ Dernier décile vs reste

## Principe de la combinaison

- ▶ Fréquence d'apparition d'une sous-population (premier ou dernier décile) dans le carreau
- ▶ Agrégation spatiale au niveau du carreau  $i$

$$p_i^{D1} = \mathbb{P}(y_x < \mu^{D1}) = \mathbb{E}(\mathbf{1}_{\{y_x < \mu^{D1}\}}) = \frac{1}{n_i} \sum_{x=1}^{n_i} \mathbf{1}_{\{y_x < \mu^{D1}\}}$$

$$p_i^{D9} = \mathbb{P}(y_x > \mu^{D9}) = \mathbb{E}(\mathbf{1}_{\{y_x > \mu^{D9}\}}) = \frac{1}{n_i} \sum_{x=1}^{n_i} \mathbf{1}_{\{y_x > \mu^{D9}\}}$$

- ▶ Si  $p_i > 0.1$ , sur-représentation de la sous-population dans le carreau
- ▶ Cette fréquence observée sert à simuler la sous-population d'appartenance des utilisateurs de téléphone vivant dans  $c_i$

## Méthodologie

# Principe

- ▶ Le statut de l'utilisateur de téléphone est simulé à partir de son profil d'appel (seule information individuelle) et caractéristiques de Filosofi
- ▶ 3 étapes pour estimer la dynamique de la ségrégation:
  1. Estimation du domicile:
    - ▶ Estimation de probabilités de résidence à partir trace d'appel en soirée: 19h-9h
  2. Tirage d'un domicile et d'un revenu
    - ▶ Simulation du domicile, sachant ces probabilités de domicile
    - ▶ Simulation du revenu, à partir fréquences calculées dans Filosofi
  3. Calcul d'indices de ségrégation
    - ▶ Dépendent des présences à un instant  $t \Rightarrow$  vision dynamique

# 1. Estimation du domicile

- ▶ Domicile probabilisé à partir trace d'appel en soirée (19h-9h)
- ▶ L'ensemble de l'espace métropolitain n'est pas résidentiel
  - ▶ Dans une aire de couverture d'antenne, *a priori* sur les carreaux où trouver un espace résidentiel est le plus probable
  - ▶ A priori à partir de la **densité du bâti résidentiel** dans le carreau (BD Topo)
- ▶ Loi *a priori* est une **repondération des probabilités de résidence**

$$\mathbb{P}_x(c_i^{\text{home}}|v_j) \propto \underbrace{\mathbb{P}(c_i^{\text{home}})}_{\substack{\text{a priori par ratio surfaces:} \\ \text{BD Topo}}} \underbrace{\mathbb{P}_x(v_j|c_i)}_{\frac{s(v \cap c)}{s(c)}}$$

- ▶ Obtient une séquence des probabilités de domicile:  
 $\nu_x^{\text{home}}(c_i)$  Définition
  - ▶ Utilisée pour simuler le domicile de  $x$

## 2. Simulation de domicile et revenu

4 méthodes de simulation domicile pour tester robustesse estimateurs de ségrégation du groupe économique  $g$  (premier ou dernier décile)

Méthode	Domicile de $x$
Méthode principale	Tirage à partir ensemble probabilités de résidence $\nu_x^{\text{home}}$
One stage simulation	Choix probabilité maximale de résidence: $c_i = \arg \max_{c_i} \nu_x^{\text{home}}(c_i)$
cell_max_proba	Domicile de $x$ fixé par la probabilité d'être membre du groupe $g$ maximale
cell_min_proba	Domicile de $x$ par la probabilité d'être membre du groupe $g$ minimale

Deux dernières méthodes: évaluer effet sur ségrégation de sur- ou sous-estimer la part du sous-groupe  $g$  dans la population

### 3. Indices de ségrégation

- ▶ Construction deux journées typiques: 24 heures de semaine, 24 heures le weekend
- ▶ Probabilités individuelles de présence dans le carreau sur la plage temporelle notée  $\mathbb{P}_x(c_{it})$  [Détails](#)
- ▶ Indice de dissimilarité (Duncan & Duncan, 1955) adapté à la probabilisation de la présence:

$$ID_t^g = \frac{1}{2} \sum_{c \in \mathcal{C}} \left| \frac{\sum_{x \in \mathcal{X}} \mathbb{P}_x(c_{it}) \mathbf{1}_{x \in g}}{\underbrace{\sum_{x \in \mathcal{X}} \mathbf{1}_{x \in g}}_{\text{Number people of income group } g \text{ that are observed at time } t}} - \frac{\sum_{x \in \mathcal{X}} \mathbb{P}_x(c_{it}) \mathbf{1}_{x \notin g}}{\underbrace{\sum_{x \in \mathcal{X}} \mathbf{1}_{x \notin g}}_{\text{Number people not in income group } g \text{ that are observed at time } t}} \right|$$

- ▶ Indice classique:

$$ID = \frac{1}{2} \sum_{c \in \mathcal{C}} \left| \frac{w_c}{W_T} - \frac{n_c - w_c}{N_T - W_T} \right|$$

## Résultats

# Dynamique de la ségrégation

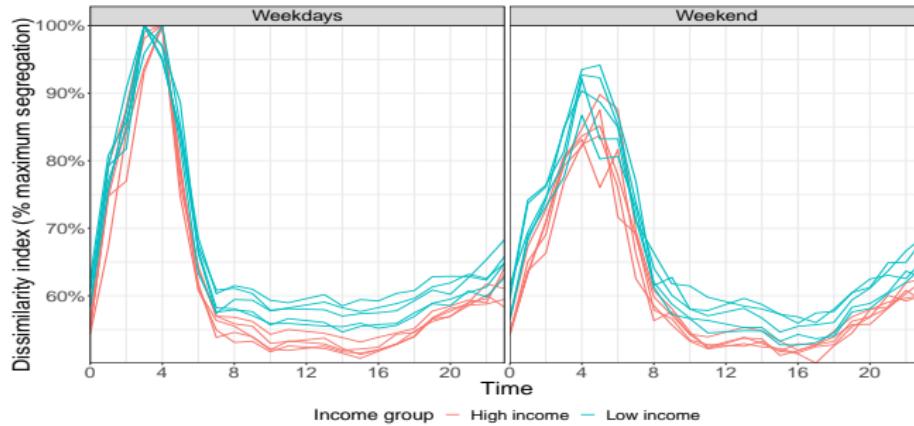


Figure 7:  
Marseille

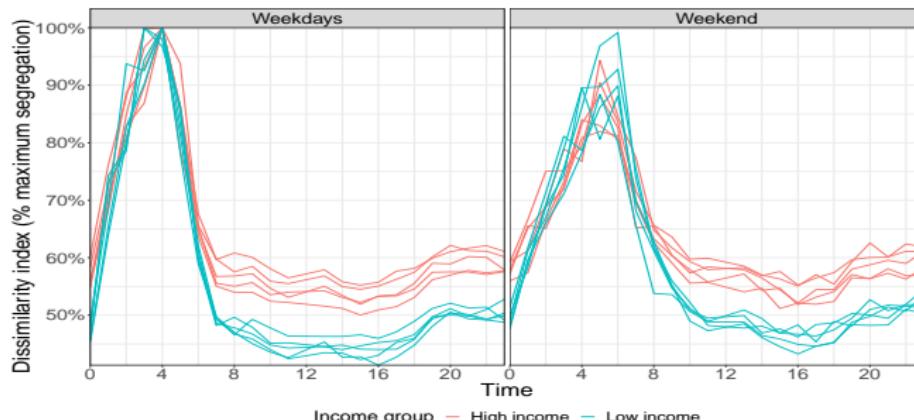


Figure 8:  
Lyon

# Robustesse: résultats pour Marseille

Resultats pour Lyon

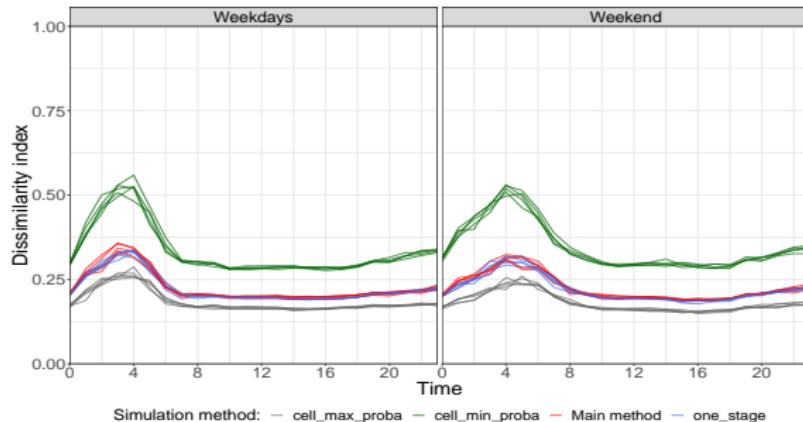


Figure 9:  
Premier  
décile

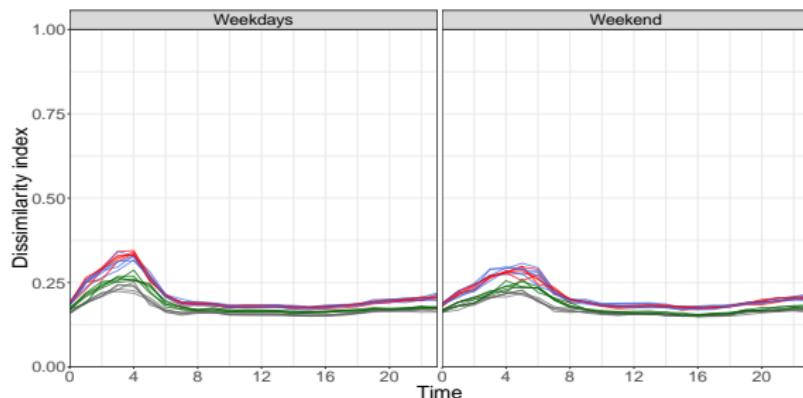


Figure 10:  
Dernier  
décile

# Comparaison aux niveaux Filosofi

- ▶ Ségrégation plus faible que dans Filosofi
  - ▶ Pas à cause de l'approche par simulation Bootstrap Filosofi
- ▶ 2 possibilités:
  1. Ne pas interpréter les niveaux mais la dynamique
  2. Utilisateurs manquants pendant la nuit: supposer qu'ils sont chez eux

	Marseille		Lyon	
	Low-income	High-income	Low-income	High-income
Dissimilarity index in tax data	0.44	0.45	0.36	0.47
Max. dissimilarity index in phone data	0.34	0.34	0.26	0.28
Difference	0.1	0.11	0.10	0.19

Recalage

# Imputation des utilisateurs non observés pendant la nuit

- ▶ Tous les utilisateurs ne sont pas observés à l'instant  $t$

$$ID_t^g = \frac{1}{2} \sum_{c \in \mathcal{C}} \left| \frac{\sum_{x \in \mathcal{X}} \mathbb{P}_x(c_{it}) \mathbf{1}_{x \in g}}{\underbrace{\sum_{x \in \mathcal{X}} \mathbf{1}_{x \in g}}_{\text{Number people of income group } g \text{ that are observed at time } t}} - \frac{\sum_{x \in \mathcal{X}} \mathbb{P}_x(c_{it}) \mathbf{1}_{x \notin g}}{\underbrace{\sum_{x \in \mathcal{X}} \mathbf{1}_{x \notin g}}_{\text{Number people not in income group } g \text{ that are observed at time } t}} \right|$$

- ▶ Quel effet sur les indices ?
- ▶ Imputer individus au domicile avec proba 1 lorsqu'ils sont manquants:
  - ▶ Imputation la nuit (19h-09h)

# Imputation des utilisateurs non observés pendant la nuit

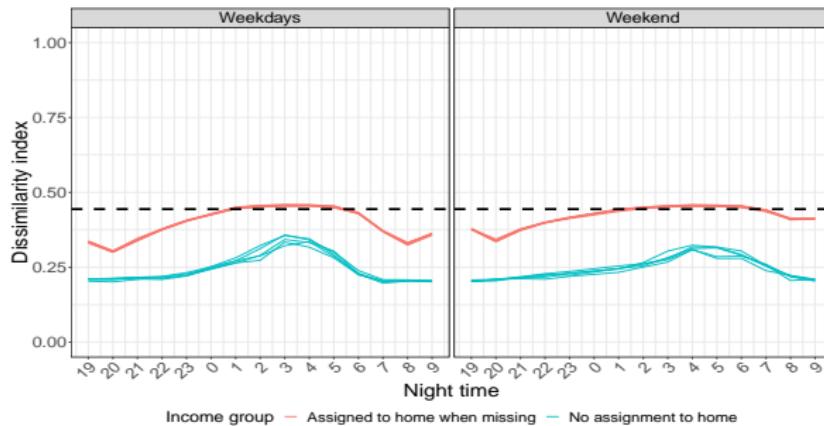


Figure 11:  
Premier  
décile

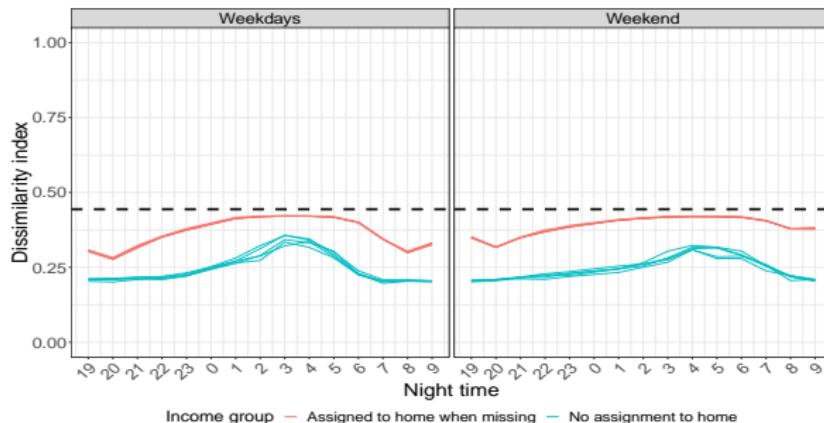
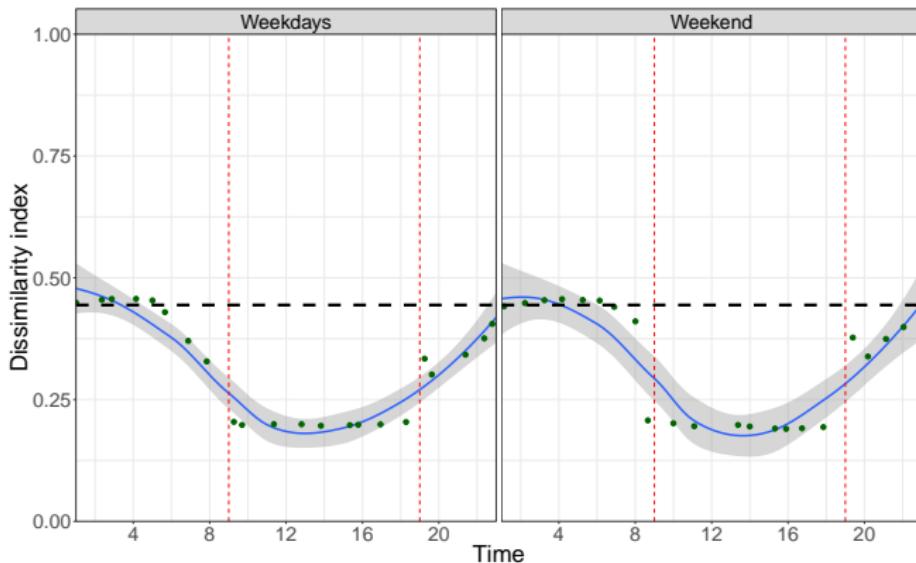


Figure 12:  
Dernier  
décile

# Imputation des utilisateurs non observés pendant la nuit

- ▶ On retrouve niveau de ségrégation cohérent avec données fiscales
- ▶ Comment traiter les heures de la journée ?



## Conclusion

# Conclusion

- ▶ Proposition d'une méthode pour combiner données de téléphonie et données administratives
- ▶ Premiers résultats à confirmer:
  - ▶ Ségrégation moins marquée pendant la journée que le suggère la ségrégation résidentielle (cohérent avec Le Roux et al., 2017)
  - ▶ Pas de différence marquée dans la dynamique entre premier et dernier déciles
  - ▶ Recalage permet d'avoir un niveau de ségrégation cohérent avec Filosofi
- ▶ Suite du travail:
  - ▶ Investissement méthodologique à approfondir
  - ▶ Généraliser à d'autres villes
  - ▶ Comprendre la dynamique de la ségrégation à une échelle infra-urbaine Exemple

I

## Appendix

## Annexe méthodologique

## Présence au carreau

- ▶ La probabilité qu'un événement mesuré dans l'antenne  $v_j$  à l'instant  $t$  ait lieu dans le carreau  $c_i$  est égal à

$$p_i^j := \mathbb{P}(c_i | v_j) = \frac{\mathbb{P}(c_i \cap v_j)}{\mathbb{P}(v_j)} = \frac{\mathcal{S}(c_i \cap v_j)}{\mathcal{S}(v_j)}$$

- ▶ La probabilité d'être présent à l'instant  $t$  dans le carreau  $c_i$  (on note cette double condition  $c_{it}$ ) est la recollection des probabilités conditionnelles

$$\forall c_{it} \in \mathcal{C}, \quad \mathbb{P}_x(c_{it}) = \sum_{v_{jt} \in \mathcal{V}} \mathbb{P}(c_{it} | v_{jt}) \mathbb{P}_x(v_{jt}) \quad (1)$$

avec  $\mathcal{V}$  ensemble des antennes/voronois et  $\mathcal{C}$  cellules de 500m.

## Estimation du domicile

- ▶ Détection domicile uniquement: événement au niveau du voronoi repondéré selon la formule suivante

$$\mathbb{P}_x(c_i^{\text{home}}|v_j) \propto \underbrace{\mathbb{P}(c_i^{\text{home}})}_{\substack{\text{a priori par ratio surfaces:} \\ \text{BD Topo}}} \underbrace{\mathbb{P}_x(v_j|c_i)}_{\frac{s(v \cap c)}{s(c)}}$$

- ▶ Domicile estimé de l'individu  $x$  au niveau du carreau  $c_i$  en sommant tous les événements mesurés au niveau des voronoi  $v_j$ :

$$\nu_x^{\text{home}}(c_i) = \frac{1}{\alpha_x} \sum_{v \in \mathcal{V}} \mathbb{P}_x(c_i^{\text{home}}|v_j) \mathbb{P}(v_j)$$

- ▶ avec  $\alpha_x$  un terme de normalisation pour avoir  $\sum_{c_i} \nu_x^{\text{home}}(c_i) = 1$

## Annexe résultats

# Robustesse: Lyon

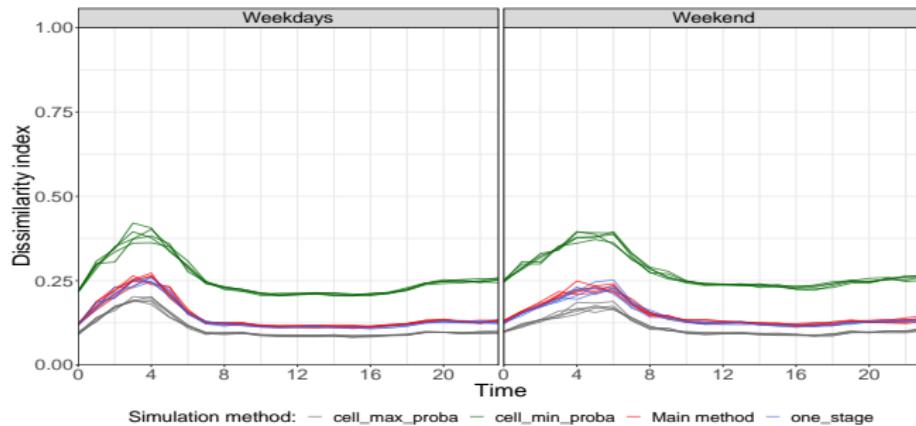


Figure 13:  
Premier  
décile

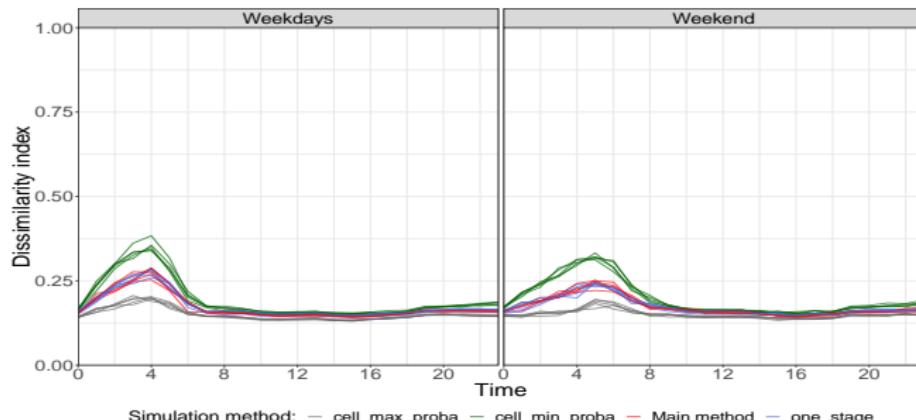


Figure 14:  
Dernier  
décile

# Effet simulation sur ségrégation: bootstrap données fiscales

		DISSIMILARITY INDEX		
		Bootstrap design		
		(1)	(2)	(3)
MARSEILLE				
Low-income	0.4441	0.4439 [0.4422;0.4455]	0.446 [0.4429;0.4502]	0.457 [0.4515;0.4611]
		0.4088 [0.4070;0.4107]	0.415 [0.4117;0.4186]	0.4226 [0.4187;0.4269]
LYON				
Low-income	0.3584	0.359 [0.3572;0.3606]	0.3626 [0.3602;0.3654]	0.352 [0.3483;0.3561]
		0.3969 [0.3944;0.3987]	0.4021 [0.3986;0.4059]	0.4028 [0.3985;0.4067]

Notes:

Median dissimilarity index over 100 iterations is reported. 95% confidence intervals are reported into brackets

(1): Bootstrap inside each cell with uniform weights (probability being chosen:  $1/n_i$ )

(2): Bootstrap inside each cell with uniform weights for 1/3 population (probability being chosen:  $\frac{1}{3n_i}$ )

(3): Bootstrap inside each cell with uniform weights for population from mobile phone data (probability being chosen:  $\frac{1}{n_{\text{phone}}}$ ).

# Cartographie de la ségrégation à 15 heures

Distribution du premier décile à 15h

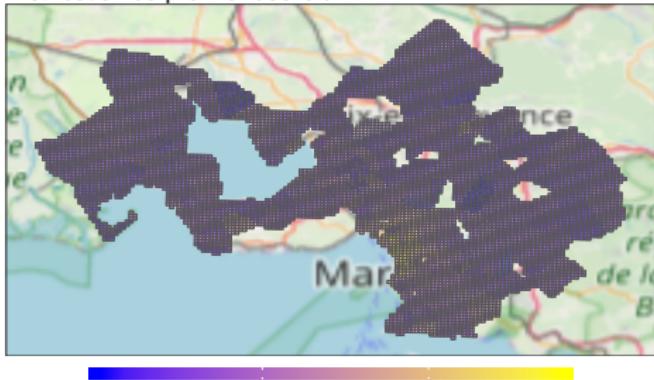


Distribution du dernier décile à 15h



# Cartographie de la ségrégation à 22 heures

Distribution du premier décile à 22h



Distribution du dernier décile à 22h

